歌声克隆系统技术深度解析

算法原理 / 量化评估 / 工程实践 / 面试问答

1. 引言与研究动机

歌声转换（Singing Voice Conversion, SVC）的目标是将一段歌声的音色（timbre）转换为目标说话人的音色，同时保持歌词内容、旋律走向、节奏和情感表达不变。其核心技术挑战在于内容与音色的解耦——模型需要从源音频中剥离原始歌手的音色特征，注入目标歌手的音色，而不破坏语言和旋律信息。从信号处理角度看，这等价于在高维声学空间中完成一次条件生成：给定内容表示c和目标音色t，生成满足p(y|c,t)分布的音频y。

本文以Hamilton音乐剧「My Shot」为实验对象。选择这首歌的原因在于它涵盖了SVC的多种典型难点：快节奏说唱（rap）段落对内容编码器的鲁棒性要求极高；抒情独唱段落需要精确的音高控制；多人合唱（ensemble）段落给单说话人模型带来严峻挑战；复杂管弦乐编曲使人声分离的质量成为关键瓶颈；频繁的段落切换则考验系统的整体稳定性。这使得它成为一个全面检验SVC系统能力的优秀测试用例。

本系统采用分离-转换-合并（Separation-Conversion-Merge）的模块化架构，依次使用Hybrid Transformer Demucs进行人声分离、基于检索增强的RVC（Retrieval-based Voice Conversion）进行音色转换、以及自适应合唱处理策略消解多声部伪影。本文将逐一深入剖析每个模块的算法原理、创新点、工程实现细节，给出完整的量化评估指标体系及其数值解读，并以面试问答的形式覆盖常见深层问题。

2. 声源分离：Demucs v4 深度解析

2.1 为什么需要声源分离

在分离-转换范式中，声源分离是整个Pipeline的第一步，也是质量瓶颈。如果分离后的人声中残留伴奏成分（尤其是中频谐波乐器如钢琴、弦乐），这些残留在RVC转换后会被放大为可听的伪影。反之，如果分离过程中丢失了人声的某些频率成分（如气息声、齿音），转换后的音频会缺乏自然感。因此，分离质量直接决定最终输出的上限。

2.2 Hybrid Transformer Demucs 架构原理

Demucs v4（代号htdemucs）由Meta的Alexandre Defossez于2021-2023年提出，是当前最先进的音乐声源分离模型之一。其核心创新是双域融合（dual-domain fusion）架构，同时在时域和频域两条路径上处理音频信号，让模型自动学习每个源在哪个域更容易被分离。

2.2.1 时域分支

时域分支接收原始波形作为输入，使用U-Net卷积网络进行编码-解码。U-Net的编码器通过多层一维卷积（kernel size=8, stride=4）逐步降低时间分辨率，提取从局部到全局的多尺度特征。解码器通过转置卷积上采样，并通过跳跃连接融合编码器的细节信息。时域处理的核心优势在于：瞬态信号（如鼓点的attack、辅音的爆破）在时域中具有高度局部化的特征，时域卷积可以精确捕捉这些快速变化。此外，时域处理天然保留相位信息，避免了频域处理中相位重建的困难。

2.2.2 频域分支

频域分支先对输入进行STFT（Short-Time Fourier Transform，窗长4096，跳步1024），将波形转换为复数频谱图，然后用类似的U-Net结构处理频谱的实部和虚部。在U-Net的瓶颈层（bottleneck），引入Transformer自注意力机制建模长距离频率依赖。频域处理的核心优势在于：谐波信号（如人声的元音、持续音符）在频域中表现为清晰的谐波峰，基频与各泛音在频率轴上等间距排列，模型可以通过频域卷积高效识别和分离这些谐波结构。此外，不同乐器的谐波模式（泛音分布、共振峰位置）在频域中具有显著的区分度。

2.2.3 双域融合机制

两个分支的特征在U-Net的中间层通过线性投影进行融合。具体来说，在编码器的每一层，时域特征经过降维投影后加到频域特征上，反之亦然。最终，两个分支各自输出分离结果，再进行加权求和。这种设计让模型可以将每个声源路由到最适合它的域：打击乐在时域分离更好，人声和旋律乐器在频域分离更好，而混合型声源（如带有明显attack的钢琴）则可以同时利用两个域的优势。

2.2.4 关键技术创新

（1）压缩残差分支：传统残差连接output = x + F(x)中，F(x)与x维度相同。Demucs引入1x1卷积对F(x)进行降维压缩，使参数量减少约50%而性能不降。（2）局部注意力：Transformer的标准全局注意力复杂度为O(n^2)，对于长音频不可承受。Demucs使用窗口大小约256帧（500ms@44.1kHz）的局部注意力，复杂度降至O(n*w)。这一设计基于音频信号的局部相关性假设——相距数秒的帧之间的直接依赖较弱。（3）奇异值正则化：对网络权重矩阵的奇异值施加约束，防止奇异值过大导致梯度爆炸，显著提升训练稳定性。

2.3 时域 vs 频域：增益与代价的深入分析

这是面试中的高频问题。以下从三个维度展开分析：

配置	人声SDR(dB)	鼓SDR(dB)	贝斯SDR(dB)	核心优势	核心劣势
仅时域	~7.0	~8.5	~7.8	瞬态保真、相位自然	谐波分离弱、人声残留多
仅频域	~7.5	~6.5	~7.0	谐波分离强、人声干净	瞬态模糊、相位重建困难
双域融合	~8.5	~8.0	~8.2	兼顾两域优势	模型参数量翻倍

表1：不同域配置下的分离性能对比（基于MUSDB18数据集估计）

深入一步思考：仅用时域处理时，人声SDR约7.0 dB，比双域低约1.5 dB。这是因为人声是典型的谐波信号，基频与泛音在频率轴上呈整数倍关系，时域卷积难以高效表达这种周期性结构。而仅用频域处理时，鼓的SDR从8.5降至6.5 dB，降幅更大。这是因为鼓点的时域脉冲在频域展开后能量分布极广（类似Dirac脉冲的宽带频谱），频域模型难以在所有频率上同时准确建模这种非稳态信号。此外，频域方法面临相位重建问题：STFT生成的复数频谱中，相位信息对波形重建至关重要，但神经网络在预测高维相位时容易引入噪声，导致重建波形中出现可听的伪影。双域融合通过让模型自主选择每个频率成分的最佳处理路径，从根本上缓解了上述问题。

2.4 htdemucs_ft 模型变体

本Pipeline选用htdemucs_ft——在MDX2021竞赛数据上微调的版本。相比基础htdemucs，htdemucs_ft在人声分离SDR上提升约0.5 dB，对混响、和声等复杂场景更鲁棒。97M参数量，推理时在消费级GPU上约需5秒处理1分钟音频。另有htdemucs_6s变体支持6轨分离（人声/鼓/贝斯/吉他/钢琴/其他），可用于更精细的伴奏控制，但总体SDR略低于4轨版本。

2.5 声源分离算法的跨领域应用

Demucs类声源分离技术不仅用于音乐场景。在语音增强中，将环境噪声视为「伴奏」，人声视为目标源，用相同架构实现降噪。在声学场景分析（Acoustic Scene Analysis）中，分离不同声源后分别分类。在音乐信息检索（MIR）中，分离出人声后进行歌词识别（Lyrics Tr

anscription）或旋律提取。在混音制作中，分离出各音轨后重新调整音量、EQ和空间定位。在法律取证中，分离通话录音中的背景声以分析环境信息。这些应用共享同一核心问题——从混合信号中恢复独立成分——差异仅在于成分的数量、性质和对分离精度的要求不同。

3. 内容编码与说话人解耦

3.1 HuBERT：自监督掩码预测

HuBERT（Hidden-Unit BERT）由Meta于2021年提出，是当前语音自监督学习的代表方法。其训练流程分为三步：（1）将原始音频提取MFCC特征，对所有帧进行K-Means聚类（聚类中心数100），得到每帧对应的离散Token ID——这相当于为音频创建了一个「伪词典」；（2）对输入音频进行随机掩码（span masking，跨度8-10帧），然后用12层Transformer编码器预测被掩码位置的Token ID——这与NLP中的BERT完全类比；（3）使用第一轮训练后模型输出的中间层特征重新聚类，得到更精确的Token，再进行第二轮训练（iterative refinement）。

HuBERT之所以能学到说话人无关的内容表示，关键在于聚类目标的设计。MFCC特征本身就对说话人信息有一定的鲁棒性，基于MFCC的聚类中心倾向于捕捉音素级别的模式而非说话人级别的模式。当Transformer被训练去预测这些聚类ID时，它学到的表示自然地偏向于内容（音素、语调）而非音色。然而，这种去除并非完全的——研究表明HuBERT特征中仍残留约15-20%的说话人信息，这为后续的ContentVec改进留下了空间。

3.2 ContentVec 的三项创新

ContentVec由Kaizhi Qian等人于2022年发表于ICML，专门针对HuBERT的说话人泄露问题进行改进。其三项核心创新如下。

（1）说话人增强聚类（Speaker-Augmented Clustering）：在聚类之前，对每段训练音频施加随机变声处理（pitch shifting、formant shifting），使得同一音素在不同音色变体下仍被分配到同一聚类中心。这迫使聚类中心只编码音素信息，彻底去除音色依赖。

（2）对比损失（Contrastive Loss）：训练时构造正样本对——同一音素的不同说话人版本——和负样本对——不同音素。通过InfoNCE损失拉近正样本对的特征距离，推远负样本对。数学上：L = -log(exp(sim(x, x+)/tau) / sum(exp(sim(x, x-)/tau))），其中tau为温度参数。这使特征空间中的距离只反映内容差异，不反映音色差异。

（3）条件预测（Conditional Prediction）：将说话人嵌入作为条件输入到学生网络。由于说话人信息已经由条件输入提供，学生网络不需要在特征中编码说话人信息即可完成预测任务。这从信息论角度保证了特征的说话人无关性。

3.3 主流内容编码器对比与共性

编码器	维度	训练方式	说话人无关性	语义保真度	适用场景
HuBERT	768	自监督掩码预测	中等	高	通用语音表示
ContentVec	256/768	自监督+对比学习	高	高	SVC首选
Wav2Vec2	768	自监督对比预测	低	最高	ASR预训练
PPG(ASR)	~80	有监督音素分类	最高	中等	跨语言SVC
Whisper	1280	有监督多任务	中等	高	多语言SVC

表2：主流内容编码器对比

所有这些编码器的共性是试图解决同一个核心问题：从语音信号中提取与说话人无关的内容表示。区别在于方法论：自监督方法（HuBERT、ContentVec、Wav2Vec2）通过无标注数据大规模预训练隐式学习内容表示；有监督方法（PPG、Whisper）通过明确的文字标注直接训练音素/文字级别的分类器。前者的优势在于不需要文字标注、特征更丰富；后者的优势在于说话人无关性可以更强（PPG只包含音素后验概率，天然不含音色信息）。本Pipeline选择ContentVec作为平衡方案。

3.4 内容编码算法的跨领域应用

HuBERT/ContentVec这类自监督语音模型在SVC之外有广泛应用。（1）自动语音识别（ASR）：HuBERT的预训练表示可以作为ASR的初始化，在LibriSpeech上达到SOTA。（2）语音情感识别（SER）：中间层特征包含丰富的韵律和情感信息。（3）说话人验证（Speaker Verification）：虽然ContentVec刻意去除说话人信息，但原始HuBERT的某些层仍保留说话人特征，可用于验证。（4）语音翻译（Speech Translation）：内容表示可以跨语言迁移。（5）语音合成（TTS）：VITS等模型使用HuBERT特征作为中间表示。这体现了自监督学习的一个重要特性：预训练表示是通用的，可以通过不同的下游任务头适配多种应用。

4. 基频估计：RMVPE 与替代方法

4.1 RMVPE 架构详解

RMVPE（Robust Multi-Voice Pitch Estimation）由Wang等人于2023年提出，专门为复音场景设计。其架构由三部分组成：前端特征提取、U-Net编码器和BiGRU时序模型。

（1）前端：输入16kHz音频，通过STFT（窗长2048，跳步160）转换为128-bin的Mel频谱。Mel频谱相比原始STFT具有更紧凑的表示，且符合人耳对频率的感知特性。（2）U-Net编码器：5层下采样卷积+残差连接，将Mel频谱编码为高层特征。U-Net的跳跃连接保留了低层的频率细节信息，使解码器能同时访问局部和全局特征。（3）BiGRU：双向GRU层建模时间依赖，使相邻帧的F0预测具有时间一致性。这对于歌声场景尤其重要——歌声的F0轨迹通常是平滑连续的，BiGRU的时序建模可以抑制因伴奏干扰导致的孤立错误帧。

（4）输出层：全连接层将BiGRU输出映射到360维的概率分布，每个维度对应一个F0候选值（覆盖约50Hz-1000Hz，以20 cents为间隔）。通过Sigmoid激活后，取概率最大的维度作为F0估计。这种建模方式的创新在于将F0估计从回归问题转化为多标签分类问题。分类方法的优势在于可以表达不确定性：当多个声部同时存在时，多个F0候选值的概率都可以较高，而回归方法只能输出一个值。

4.2 F0 估计方法对比

方法	架构	准确率(复音)	计算速度	核心原理
RMVPE	U-Net+BiGRU	95.2%	中等	多标签Mel分类
CREPE	CNN(6层)	87.3%	慢	回归预测+置信度
PM	自相关	~70%	极快	时域自相关峰检测
Harvest	DIO改进	~75%	快	多级候选+Viterbi选优
FCPE	CNN+Transformer	~93%	快	分类+快速推理

表3：主流F0估计方法对比

RMVPE在复音场景下的准确率（95.2%）显著高于其他方法，这是因为U-Net的多尺度卷积可以在频域中分离主旋律的谐波与背景乐器的谐波，而BiGRU的时序平滑进一步抑制了因短暂遮挡导致的误检。CREPE虽然在干净人声上表现优秀，但其纯CNN架构缺乏时序建模能力，面对快速变化的复音环境容易产生F0跳变。传统方法（PM、Harvest）基于自相关函数检测周期性，在存在多个周期性成分的复音信号中极易产生八度误差（将泛音误判为基频）。

4.3 F0 之外的替代方案

除了显式提取F0作为音高条件，还存在以下替代路线：

（1）DDSP直接波形建模：DDSP（Differentiable Digital Signal Processing）使用可微分的谐波振荡器和噪声滤波器直接合成波形。模型只需学习振荡器的频率和幅度参数，而不需要显式的F0提取步骤。缺点是输出会带有「电音感」，需要额外的浅扩散步骤来增强自然度。（2）学习式音高表示：不使用传统F0（单一频

率值），而是学习一个连续的音高嵌入向量。例如RIFT-SVC使用RMVPE提取F0后再通过MLP映射到嵌入空间，这比直接使用裸F0值包含更多的音高上下文信息。（3）音高无关方法：某些端到端SVC模型（如Vevo1.5的FM模式）完全不使用显式F0，而是通过Tokenizer将音高信息编码为离散的韵律Token。优势在于避免了F0提取错误的传播，但代价是音高控制的精细度降低。（4）多F0估计：在合唱场景中，可以同时估计多条F0轨迹（如RMVPE的多标签输出），选择与目标说话人最接近的一条。这是本系统增强F0策略的理论基础。

4.4 F0 估计的跨领域应用

F0估计技术在SVC之外广泛应用于：音乐信息检索（自动旋律转录AMT）、语调分析（语言学研究中的声调模式识别）、韵律建模（TTS中的情感和风格控制）、歌唱评分（卡拉OK系统的音准评估）、以及医学领域的嗓音病理诊断（通过F0的jitter和shimmer分析发声障碍）。

5. VITS 声学模型框架深度解析

VITS（Variational Inference with adversarial learning for end-to-end Text-to-Speech）由Kim等人于2021年发表于ICML。RVC在VITS基础上增加了检索模块和F0条件NSF-HiFiGAN声码器。VITS的核心是将三种生成范式——VAE、正则流、对抗训练——统一在一个端到端框架中。理解为什么需要这三者的结合，是深入理解RVC的关键。

5.1 条件变分自编码器（Conditional VAE）

VAE将音频生成建模为潜变量模型。给定内容条件c（HuBERT特征+F0），目标是学习条件生成分布p(y|c)。VAE引入潜变量z将其分解为：p(y|c) = integral p(y|z,c) p(z|c) dz。训练时使用ELBO（证据下界）优化：

```
ELBO = E_q(z|y)[log p(y|z,c)] - KL[q(z|y) || p(z|c)]
```

其中q(z|y)是后验编码器（Posterior Encoder），处理真实音频的线性频谱，输出均值mu和方差sigma参数化的高斯分布。p(z|c)是先验编码器（Prior Encoder），处理内容条件c，输出先验分布。p(y|z,c)是解码器（NSF-HiFiGAN），从z和条件c生成波形。第一项（重建损失）鼓励解码器忠实地重建音频；第二项（KL散度）鼓励先验分布接近后验分布，使推理时只用先验即可生成高质量音频。

一个常见的深入问题是：为什么不直接用编码器-解码器（Autoencoder）？答案在于推理时的泛化能力。AE只能重建训练集中见过的样本，而VAE通过在潜变量空间中施加先验约束，学到了一个连续的、可插值的生成分布。推理时从先验p(z|c)采样即可生成未见过的说话人的声音。

5.2 正则流（Normalizing Flow）

VAE的一个根本局限是先验p(z|c)通常被设定为简单的高斯分布，而真实的后验q(z|y)可能是高度复杂的多模态分布。当两者差距过大时，KL散度项的优化会导致「后验坍塌」——后验退化为先验，潜变量z不再携带有用信息。

正则流通过一系列可逆变换将简单分布变换为复杂分布，弥合先验-后验的差距。VITS使用残差耦合层（Residual Coupling Layer）构建流：将输入x沿通道维度分为x0和x1两半，用x0通过一个变换网络计算偏移量h，将x1变换为x1+h。由于只有加法操作，这个变换是可逆的（反向时x1-h即可恢复），且Jacobian行列式易于计算。4层耦合层叠加后，先验分布被变换为足以拟合后验的复杂分布。

没有正则流会怎样？实验表明，去掉Flow后MCD恶化约0.8 dB，生成音频的多样性降低（趋于均值输出），尤其在高音区和快速旋律变化处可以听到明显的质量下降。这印证了Flow在缩小先验-后验差距方面的必要性。

5.3 对抗训练与多周期判别器

VAE+Flow虽然解决了分布匹配的问题，但VAE的重建损失（L1或L2 on Mel频谱）本质上是逐点的均方误差，它鼓励生成「平均值」而非「最真实」的结果。这导致生成音频缺乏高频细节，听起来「模糊」或「过度平滑」。

对抗训练通过引入判别器D解决此问题。VITS采用HiFi-GAN风格的多周期判别器（MPD），包含5个子判别器，分别以周期2、3、5、7、11对音频进行reshape后判别。不同周期捕捉不同频率范围的失真：周期=2主要捕捉高频细节（如齿音、气息声），周期=11则关注低频包络（如基频的稳定性）。使用LSGAN损失（(D(y_real)-1)^2 + D(y_fake)^2）代替原始GAN的交叉熵损失，训练更稳定。此外还加入特征匹配损失（Feature Matching Loss）——让生成音频在判别器各层的中间表示与真实音频尽可能接近。

没有GAN会怎样？去掉对抗训练后，生成音频的MOS（Mean Opinion Score）下降约0.3-0.5分，主要表现为高频细节缺失、齿音不清晰、整体声音偏「闷」。这说明GAN在补充VAE重建损失无法捕捉的感知细

节方面是不可替代的。

5.4 NSF-HiFiGAN 声码器

NSF-HiFiGAN是RVC使用的声码器，它在标准HiFi-GAN的基础上引入了神经源-滤波器（Neural Source-Filter）模型。标准HiFi-GAN从Mel频谱直接生成波形，不使用任何显式的声源信息。而NSF-HiFiGAN额外接收F0作为条件输入：先用F0驱动一个正弦振荡器生成谐波激励信号（source），再用神经网络作为滤波器（filter）对激励进行整形。这保证了输出波形的基频与输入F0严格一致，避免了声码器「自行决定」音高导致的偏差。在SVC场景中，音高准确度是核心指标之一，NSF-HiFiGAN的F0条件机制使其成为最佳选择。

5.5 三位一体：为什么缺一不可

配置	音质	多样性	训练稳定性	核心问题
仅VAE	过度平滑	低	高	L2损失导致模糊
仅GAN	细节丰富	低(模式坍塌)	低	训练不稳定，模式坍塌
仅Flow	理论最优	高	中等	计算成本高，需大量数据
VAE+Flow	中等偏上	高	高	高频细节不足
VAE+Flow+GAN	最佳	高	高	参数量大（可接受）

表4：不同生成框架配置的特性对比

类比来说，这三者的关系类似于大语言模型中的预训练（VAE提供基础能力）、RLHF（GAN提供人类偏好对齐）和Chain-of-Thought（Flow提供推理能力）的组合——单独使用任何一个都不足以达到最佳效果，组合使用才能发挥协同优势。

6. 检索增强机制：FAISS Top-k

6.1 FAISS 索引原理

RVC的核心创新是在VITS框架上添加了特征检索模块。训练完成后，将所有训练数据的ContentVec特征（每帧768维向量）构建为FAISS（Facebook AI Similarity Search）向量索引。FAISS支持多种索引类型：Flat（暴力搜索，最精确但最慢）、IVF（倒排文件索引，将向量空间划分为nlist个Voronoi区域，只在相邻区域内搜索）、PQ（乘积量化，将高维向量分段压缩后近似搜索）。RVC默认使用IVFFlat索引，nlist根据数据量自动设定。

推理时，对源音频的每帧ContentVec特征在索引中搜索Top-k（k=8）最近邻，取距离加权平均作为检索特征h_retrieved。最终特征 h_final = (1 - index_rate) * h_source + index_rate * h_retrieved，其中index_rate控制检索特征的混合比例。当index_rate=0时完全使用源特征（无检索增强），当index_rate=1时完全使用检索特征。推荐值为0.75——此时源特征仍保留25%以维持内容准确性，而75%的检索特征引入了大量目标说话人的音色信息。

6.2 为什么检索有效

检索模块的本质是非参数记忆（Non-parametric Memory）。对于小数据集（如本系统的10分钟训练数据），模型的参数化记忆有限，难以为所有可能的音素-音高组合学到准确的目标音色映射。而检索模块通过直接「查表」——从训练集中找到最相似的特征片段——绕过了参数化学习的限制。这本质上等价于k-NN回归，在训练数据稀疏时比参数化模型更可靠。这也解释了为什么RVC只需10分钟数据即可获得较好的效果，而没有检索模块的So-VITS-SVC需要数小时数据。

6.3 检索增强在其他领域的应用

检索增强是一种通用的模型增强范式。在NLP领域，RAG（Retrieval-Augmented Generation）将文档检索与语言模型结合，让GPT类模型可以引用外部知识而无需全部记忆在参数中。在机器翻译中，k-NN MT从翻译记忆库中检索相似句对来辅助翻译。在计算机视觉中，检索增强图像生成从数据库中检索相似图像作为条件。这些应用共享同一个insight：当参数化模型的记忆容量不足时，外部检索可以作为补充，提供精确的局部信息。RVC的Top-k检索是这一范式在语音领域的成功实践。

7. 合唱段落处理策略

7.1 问题根因

Hamilton「My Shot」包含大量多人合唱段落。当这些段落通过单说话人RVC模型处理时，会产生严重的伪影。根本原因有三：（1）ContentVec在多声部输入时特征混乱——多个说话人的语音内容叠加，编码器无法区分主旋律与和声，输出的内容特征是多个说话人信息的混杂体。（2）RMVPE面临多基频并存——合唱时存在多条F0轨迹，虽然RMVPE的360-bin分类输出可以检测到多个F0峰，但最终仍需选择一条，选择错误时会导致音高跳变（例如从主旋律跳到高八度的和声）。（3）VITS解码器接收到不一致的条件信号（混杂的内容特征+不稳定的F0），生成的波形包含频谱拼接伪影——听感上呈现电流音或机械感。

7.2 策略A：合唱段原声回退

核心思想：放弃对合唱段落的音色转换，保留Demucs分离的原始人声作为背景合唱。在合唱段边界使用Sigmoid交叉淡化避免突兀的音色切换。淡化函数 w(x) = sigma(6*(x-0.5))，其中x归一化到[0,1]。Sigmoid相比线性淡化的优势在于：中间区域变化快（减少「双声」时间），边缘区域变化慢（过渡更平滑）。合唱段音量默认降低6dB，使其在混音中退居背景角色。优势：完全消除多声部伪影，保持原始合唱和声效果。代价：合唱段的音色未被转换，存在音色不一致。

7.3 策略B：增强F0估计

对于轻度和声段落（2-3个声部），直接放弃转换过于保守。策略B通过四项F0增强措施使RVC在合唱段也能产生较好输出：（1）强化中值滤波：kernel从默认的3增大到11，抑制多声部干扰导致的F0脉冲噪声。（2）谐波先验纠正：用独唱段落的F0中位数作为先验，检测并纠正合唱段中的八度误差（偏移超过600 cents且接近整数倍关系的帧）。（3）连续性约束：限制帧间F0跳变不超过200 cents（约2个半音），超过阈值的帧被线性插值替换。（4）高斯平滑：sigma=2.0的高斯核对F0序列做最终平滑。这四项措施层层递进，从滤波、纠错、约束到平滑，全面提升合唱段F0的质量。

7.4 自适应混合策略

对每个检测到的合唱段落，计算声部密度分数：score = 0.4*chroma_entropy + 0.25*RMS_energy + 0.25*harmonic_ratio+0.15*spectral_bandwidth。各特征经Z-score归一化到[0,1]区间。色度熵（chroma entropy）反映同时活跃的音高类别数——合唱声部越多，12个色度通道的能量分布越均匀，熵越高。当密度分数超过阈值0.7时，采用策略A（原声回退）；否则采用策略B（增强F0）。这种自适应机制避免了一刀切的处理方式，对重度合唱（4+声部）使用最保守的策略，对轻度和声（2-3声部）仍尝试转换以保持音色统一。

8. 量化评估指标深度解析

本章详述每个指标的精确计算方式、数值范围解读和应用场景。理解这些指标不仅对系统评估至关重要，也是面试中的高频考点。

8.1 MCD（Mel-Cepstral Distortion）

```
MCD = (10*sqrt(2)/ln(10)) * (1/T) * sum_t ||mc_ref(t) - mc_conv(t)||_2
```

计算步骤：（1）将参考和转换音频重采样至16kHz；（2）提取13维MFCC（排除第0维能量系数），帧长25ms，帧移10ms；（3）对齐帧数（截断较长序列或DTW对齐）；（4）逐帧计算13维MFCC向量的欧氏距离；（5）乘以系数alpha = 10*sqrt(2)/ln(10) = 6.14，取所有帧的平均值。系数6.14的来源：MFCC定义中的DCT变换引入了sqrt(2/N)的归一化因子，alpha将其转换为dB刻度下的可比较量。

范围(dB)	等级	听感描述
< 5.0	优秀	转换与参考几乎无法区分
5.0 - 6.5	良好	可察觉差异但不影响听感
6.5 - 8.0	中等	差异明显，部分段落失真
> 8.0	较差	严重频谱失真，影响可懂度

表5：MCD数值范围解读

MCD的局限性：它衡量的是频谱包络（spectral envelope）的距离，不考虑精细的谐波结构和时间动态。两段MCD相同的音频，一段可能自然流畅，另一段可能有明显的不连续感。此外，MCD对采样率、MFCC提取参数敏感，跨系统比较时需确保配置一致。MCD广泛用于：语音合成评估（TTS/VC quality benchmark）、语音编解码器质量评测、助听器算法评估等领域。

8.2 F0-RMSE（Hz 与 cents）

```
F0-RMSE(Hz) = sqrt((1/N) * sum_n (f_ref(n) - f_conv(n))^2) [■■■■]
F0-RMSE(cents) = sqrt((1/N) * sum_n (1200 * log2(f_conv(n) / f_ref(n)))^2)
```

Hz和cents两种刻度各有用途。Hz刻度在低音区更敏感（如100Hz和105Hz相差5Hz但仅约86 cents），在高音区不够敏感（如1000Hz和1050Hz同样差50Hz但约87 cents）。cents刻度按对数频率计算（1200 cents = 1个八度 = 频率翻倍），与人耳对音高的感知特性一致——人耳感知音高间隔遵循对数规律而非线性。因此，cents刻度更适合评估歌声场景的音高准确度。

刻度	优秀	良好	中等	较差
Hz	< 10	10-20	20-40	> 40
cents	< 30	30-60	60-100	> 100

表6：F0-RMSE数值范围解读（100 cents = 1个半音）

8.3 F0 Pearson 相关系数与 VDA

F0 Pearson相关系数衡量的是旋律轮廓（contour shape）的一致性，而非绝对频率的接近度。即使存在全局音高偏移（transpose），只要旋律走向（升降模式）一致，相关系数仍然很高。这对SVC场景特别有意义——如果目标说话人的音域与源歌手不同，可能需要整体移调，此时F0-RMSE会增大但F0-Corr应保持不变。r > 0.95表明旋律轮廓高度一致，r < 0.85表明存在旋律失真。

VDA（Voicing Decision Accuracy）衡量清浊音判定的一致性。对每帧比较参考和转换音频的清/浊音标签（F0>0为浊音，F0=0为清音），计算一致率。VDA < 0.90意味着大量帧的清浊音决策被翻转，听感上表现为不自然的气息声或多余的无声段。

8.4 说话人余弦相似度（SpkSim）

```
cos_sim = (e_conv . e_target) / (||e_conv|| * ||e_target||)
```

说话人余弦相似度使用预训练的说话人嵌入模型（如ECAPA-TDNN、Resemblyzer）提取音频的固定维度嵌入向量，然后计算余弦相似度。ECAPA-TDNN在VoxCeleb上预训练，输出192维嵌入；Resemblyzer基于GE2E损失，输出256维嵌入。本系统同时计算与目标说话人和源说话人的相似度：与目标说话人的相似度越高越好（>0.75为良好），与源说话人的相似度越低越好（<0.4表示音色泄漏较少）。

局限性：预训练模型主要在语音数据（VoxCeleb）上训练，对歌声场景的适应性有限。歌声中的vibrato、falsetto等技巧可能影响嵌入质量。此外，SpkSim只反映全局音色相似度，无法捕捉时间维度上的局部音色不一致（如某些段落转换好、某些段落音色泄漏严重的情况）。在更严格的评估中，应结合MOS听感测试进行综合判断。

8.5 PESQ（感知语音质量评估）

PESQ（ITU-T P.862标准）通过模拟人耳的感知处理来评估语音质量。其核心算法包括：时间对齐（补偿传输延迟）、Bark频域映射（将频率轴映射到24个人耳临界频带）、响度映射（将功率转换为感知响度）、对称/非对称扰动计算。最终输出MOS-LQO分数，范围1.0-4.5（满分4.5）。PESQ-WB（宽带版本）适用于16kHz音频。

在SVC场景中使用PESQ的重要注意事项：PESQ是为电话语音质量评估设计的，其感知模型（频率权重、时间掩蔽）针对的是窄带/宽带语音信号。歌声的频率范围更广、动态范围更大、存在vibrato和melisma等特殊发声技巧，这些都超出了PESQ模型的假设范围。因此，PESQ在SVC中只能作为参考指标，其绝对数值的意义弱于相对排序的意义。更适合SVC的感知评估应该是POLQA（P.863）或自定义的MOS测试。

8.6 SDR 与 SNR

```
SDR(dB) = 10 * log10(||s_target||^2 / ||e_total||^2)
```

SDR（信号失真比）是声源分离领域的标准评估指标。将误差分解为三部分：目标失真、干扰和伪影。SDR越高表示分离/转换质量越好。在本Pipeline中，SDR主要用于评估Demucs分离的人声质量（SDR约8.5 dB for htdemucs_ft）。SNR（信噪比）更简单，只考虑信号功率与噪声功率的比值。SDR > 10 dB通常表示高质量分离，5-10 dB为可接受，< 5 dB则伪影明显。这两个指标广泛用于：音乐源分离评估、语音增强评估、音频编解码器质量、助听器降噪算法评估和通信系统质量评测。

8.7 频谱收敛度（SC）与对数频谱距离（LSD）

```
SC = ||S_ref - S_conv||_F / ||S_ref||_F
LSD = sqrt((1/T) * sum_t (1/K) * sum_k (log|S_ref(t,k)|^2 - log|S_conv(t,k)|^2)^2)
```

SC使用Frobenius范数衡量频谱矩阵的整体偏差，值域[0,+inf)，越小越好。LSD在对数域计算，与人耳对音量的感知更一致（人耳感知响度遵循对数关系）。SC < 0.3为优秀，0.3-0.5为良好；LSD < 1.0为优秀，1.0-1.5为良好。这两个指标不需要参考-转换的时间对齐，适用于无法精确对齐帧的场景，在声码器质量评估和音频压缩评估中也广泛使用。

9. 实验结果与分析

9.1 实验配置

歌曲：Hamilton - My Shot (Original Broadway Cast Recording)，时长5分27秒。目标说话人：12分钟中文朗读录音（M4A，44.1kHz）。GPU：NVIDIA A800 80GB。RVC v1架构（40kHz采样率，256维HuBERT），训练200 epochs，batch size 32。推理参数：index_rate=0.75, filter_radius=3, protect=0.33。Demucs模型：htdemucs_ft。

9.2 Pipeline 整体评估

指标	数值	等级	解读
MCD (dB)	6.82	中等偏上	说唱段拉高均值，独唱段约5.94
F0-RMSE (Hz)	18.7	良好	RMVPE对单声部估计准确
F0-RMSE (cents)	52.3	良好	约半个半音偏差，听感可接受
F0-Corr	0.924	良好	旋律轮廓高度相关
VDA	0.918	良好	清浊音判定一致性较高
SpkSim(目标)	0.741	良好	音色相似度中等偏上
SpkSim(源,泄漏)	0.382	良好	原歌手音色残留较低
PESQ-WB	2.87	中等	PESQ对歌声场景参考价值有限
SNR (dB)	28.4	良好	信噪比充足

表7：Pipeline整体评估结果（有声源分离）

9.3 有/无声源分离消融实验

消融实验的核心目的是量化声源分离对转换质量的贡献。Pipeline A（标准流程）先用Demucs分离人声再转换，Pipeline B（消融）直接将混合音频输入RVC转换。两者使用完全相同的训练模型。

指标	Pipeline A (有分离)	Pipeline B (无分离)	变化幅度
MCD (dB)	6.82	11.47	+68%
F0-RMSE (Hz)	18.7	43.2	+131%
F0-Corr	0.924	0.671	-27%
SpkSim(目标)	0.741	0.529	-29%
PESQ-WB	2.87	1.62	-44%
SNR (dB)	28.4	14.7	-48%

表8：有/无声源分离消融实验

结果极具说服力：无分离Pipeline的所有指标全面恶化。MCD恶化68%（6.82→11.47 dB），表明伴奏的谐波结构严重污染了频谱建模。F0-RMSE恶化131%（18.7→43.2 Hz），说明伴奏中的周期性成分（如贝斯、弦乐）严重干扰了RMVPE的F0估计。SpkSim从0.741降至0.529，意味着伴奏成分被编码为说话人特征的一部分，扭曲了音色空间。这些数据有力地证明了：对于Hamilton这类复杂编曲歌曲，声源分离不是可选的预处理步骤，而是保证转换质量的必要前提。

9.4 合唱段落处理效果

指标	独唱段	合唱段 (未处理)	合唱段 (混合策略)	改善幅度
MCD (dB)	5.94	9.38	6.21	-33.8%
F0-RMSE (Hz)	12.1	38.9	14.7	-62.2%
F0-Corr	0.961	0.723	0.942	+30.3%
SC	0.312	0.587	0.338	-42.4%

表9：独唱/合唱段落分区域评估

合唱段未处理时MCD高达9.38 dB（比独唱段差58%），F0-RMSE是独唱段的3.2倍。应用混合策略后，MCD降至6.21 dB（降幅33.8%），F0-Corr从0.723恢复到0.942（接近独唱段的0.961）。这表明自适应混合策略有效地将合唱段的质量提升到接近独唱段的水平。

10. 主流方法共性与技术趋势

10.1 主流SVC方法的共性

纵观当前SVC领域的主流方法（RVC、So-VITS-SVC、RIFT-SVC、DDSP-SVC、SeedVC、Vevo1.5等），可以提炼出以下共性模式：

（1）内容-音色解耦是核心问题：所有方法都需要将内容表示与音色表示分离。区别在于实现方式——自监督表示学习（HuBERT/ContentVec）、有监督音素分类（PPG）、或离散Token化（VQ-VAE）。（2）条件生成是统一框架：无论使用VAE+Flow（RVC/So-VITS）、扩散模型（DiffSVC）、还是Flow Matching（RIFT-SVC/Vevo1.5），本质都是在做条件生成——给定内容条件c和音色条件t，生成音频y~p(y|c,t)。（3）预训练+微调是标准范式：大规模预训练（HuBERT在960h语音上预训练、Vevo在101k小时数据上预训练）+目标说话人微调（RVC只需10分钟）。这与NLP中的Foundation Model + Fine-tuning范式完全一致。（4）F0是歌声场景的关键信号：几乎所有SVC方法都显式使用F0作为条件输入。这是因为歌声中音高的变化范围远大于语音（2-3个八度 vs 半个八度），模型难以仅从内容特征中隐式推断如此大范围的音高变化。

10.2 技术趋势

（1）Flow Matching取代传统扩散：RIFT-SVC、SeedVC、Vevo1.5均采用Flow Matching，其优势在于采样路径更直（Rectified Flow学习直线轨迹），推理步数可从1000步压缩到30步左右，速度提升30倍+而质量几乎不降。（2）零样本能力成为标配：SeedVC、Vevo1.5、SaMoye均支持零样本转换，只需一段参考音频即可转换，无需目标说话人的训练数据。但零样本在音色相似度上仍弱于微调方案约5-10%。（3）DiT（Diffusion Transformer）统一架构：Transformer正在取代U-Net成为生成模型的标准骨架，原因在于更好的可扩展性（scaling law）和长距离建模能力。（4）多模态融合：Vevo1.5展示了同一框架同时处理TTS和SVC的可能性，未来可能出现统一的语音-歌声-音乐生成基座模型。

11. 面试深度问答

以下问题覆盖系统设计中的关键决策点和深层技术理解。

Q1: 时域和频域一起处理，只用时域或只用频域分别带来哪些增益？全用又多出什么问题？

仅用时域处理：增益在于天然保留相位信息，且对瞬态信号（鼓点attack、辅音爆破）的捕捉更精确，因为时域卷积直接操作波形采样点，时间分辨率最高。问题在于对谐波信号（人声元音、弦乐持续音）的分离能力弱——谐波信号在时域中是延展的准周期波形，时域卷积的有限感受野难以跨越多个周期建模。人声SDR约比双域低1.5 dB。

仅用频域处理：增益在于谐波信号在频率轴上呈清晰的离散峰，频域卷积/注意力可以高效识别和分离不同声源的谐波模式。问题有二：（a）瞬态信号在频域中展开为宽带能量，难以分离（鼓SDR降约2 dB）；（b）相位重建困难——STFT的幅度谱可以被神经网络准确预测，但相位谱的高维结构（相位缠绕、不连续性）使预测困难，相位误差导致重建波形中出现可听伪影。

双域融合处理：整合两域优势，模型可以将每个源路由到最适合的域处理。额外代价：参数量翻倍（约97 M），推理时间增加约50%，以及融合层的设计增加了架构复杂度。但对于追求最高分离质量的场景，这些代价是值得的。

Q2: 除了提取F0，还有什么可能的替代方法来建模音高？

（1）DDSP直接合成：完全不提取F0，用可微分谐波振荡器学习频率参数。优势在于避免F0提取误差传播；缺点是音质有「电子感」。（2）连续音高嵌入：将F0通过MLP映射为高维嵌入向量而非直接使用频率值。嵌入中可以编码更丰富的音高上下文（如是否处于vibrato中、当前音高相对于说话人平均音域的位置）。RIFT-SVC V3采用此方案。（3）音高Token化：Vevo1.5的韵律Tokenizer将F0离散化为Token序列，用自回归Transformer预测。优势在于可以捕捉长距离的音高模式（如一个乐句的整体走向），但分辨率受Token粒度限制。（4）音高无关端到端方法：某些方法（如部分扩散模型）让生成器自行从频谱中推断音高，不显式提供F0。理论上可行，但实践中在大范围音高变化（歌声场景）下性能不稳定。总结：显式F0提取仍是最可靠的方案，但融入学习式嵌入是明确的改进方向。

Q3: 为什么VITS需要VAE+Flow+GAN三者结合？去掉任何一个会怎样？

VAE提供稳定的训练信号（ELBO目标是可解析的优化目标），但L2重建损失导致过度平滑。去掉VAE只用GAN：训练不稳定，模式坍塌风险高，且缺乏概率推理能力（无法采样多样化结果）。Flow缩小先验-后验差距，使推理时从先验采样也能获得高质量结果。去掉Flow：先验退化为简单高斯，MCD恶化约0.8 dB，高音区和快速旋律处质量明显下降。GAN通过判别器补充感知细节（高频纹理、齿音清晰度）。去掉GAN：MOS下降约0.3-0.5分，声音偏「闷」。三者是互补的：VAE负责稳定的基础训练，Flow负责分布匹配的精度，GAN负责感知层面的锐化。这种组合策略已经被后续很多工作验证为有效的范式。

Q4: 检索模块的index_rate如何影响结果？为什么不直接设为1.0？

index_rate=1.0意味着完全用检索到的训练集特征替换源特征。问题是：如果训练集中没有与当前输入完全匹配的帧（而10分钟训练数据几乎不可能覆盖所有可能的音素-音高组合），检索到的「最近邻」可能与当前帧存在语义差异，导致内容保真度下降——表现为部分音节模糊或替换为相似但不同的音素。index_rate=0.75是一个经验最优值，保留25%的源特征维持内容准确性，同时引入75%的目标音色信息。实际调参建议：数据量>30分钟时可尝试0.8-0.9（检索更可靠）；数据量<10分钟时可尝试0.5-0.7（避免检索误差）。

Q5: 分离-转换-合并的Pipeline方法，误差累积如何缓解？

误差累积是模块化方法的根本局限——分离阶段的伴奏残留会被转换阶段放大，转换阶段的音色失真会在合并阶段与伴奏叠加后更加明显。缓解策略包括：（1）提升每个阶段的上限——使用最强的分离模型（h

tdemucs_ft SDR 8.5dB）、最精确的F0估计（RMVPE）、最鲁棒的内容编码器（ContentVec）。（2）在模块间添加后处理——分离后使用频谱减法去除微弱伴奏残留，转换后使用F0平滑消除跳变。（3）端到端微调——在模块化训练后，用少量端到端数据对整个Pipeline进行联合微调，这是YingMusic-SVC的策略。（4）终极方案是转向端到端架构（如RIFT-SVC、Vevo1.5），从根本上消除中间步骤的误差传播。但当前端到端方案在训练数据需求和推理成本上仍有劣势。

Q6: 合唱段的检测为什么使用色度熵而非简单的能量阈值?

能量阈值无法区分「响亮的独唱」和「安静的合唱」。合唱的本质特征是多个音高同时活跃，而非音量大。色度熵（chroma entropy）将音频投影到12个色度通道（C, C#, D, ... B），计算能量分布的Shannon熵。独唱时通常只有1-2个色度通道活跃（基频及其相邻音），熵较低；合唱时3-5个色度通道同时活跃，熵显著升高。这使得色度熵成为检测「声部密度」的天然指标。结合谐波比率（区分谐波叠加vs噪声性伴奏）、RMS能量和频谱带宽，形成多维度的合唱检测特征，鲁棒性远高于单一阈值方法。

Q7: 为什么选择RVC而非最新的端到端方案（如RIFT-SVC V3或Vevo1.5）？

选择RVC基于三方面考量：（1）数据效率：RVC只需10分钟训练数据+40分钟训练时间，而RIFT-SVC需要更多数据和更长训练时间，Vevo1.5需要大规模预训练。（2）社区成熟度：RVC拥有34.9k GitHub Stars、活跃的社区、丰富的教程和预训练模型，问题排查容易。端到端方案的社区相对年轻，文档和工具链不够完善。（3）可控性：模块化设计允许独立调整每个阶段（如更换分离模型、调整混音参数、添加后处理），端到端方案的可控性相对较弱。但需要承认，端到端方案在音质上限、误差传播和架构简洁性方面有明确优势，随着生态成熟，它们可能成为未来的主流选择。

Q8: MOS主观测试与客观指标的关系是什么？为什么需要两者?

客观指标（MCD、F0-RMSE等）可以自动化计算，适合大规模实验对比，但它们度量的是信号层面的差异，不直接反映人耳感知。例如，一段音频的MCD很低但有短暂的click噪声，MCD几乎不变但听感严重受损。MOS（Mean Opinion Score）由人类听众评分（1-5分），直接反映感知质量，但成本高（需要至少20名听众、受控听测环境），且结果受听众背景、评分标准等因素影响。最佳实践是：用客观指标做大量A/B对比实验（快速迭代），用MOS做最终的质量确认（发表/上线前）。二者的相关性约为0.7-0.8（MCD与MOS的Pearson相关），说明客观指标能大致反映感知趋势但不能完全替代主观评估。这也是为什么SVC Challenge 2025同时使用客观指标和MOS进行排名。

Q9: 如果要处理更多语言的歌声（如日语、韩语），系统需要哪些改动?

ContentVec基于LibriSpeech（英语）预训练，但自监督模型的一个重要特性是跨语言迁移能力。实验表明HuBERT/ContentVec在未见过的语言上仍能提取有效的内容特征，因为它学习的是通用的声学模式（元音/辅音区分、音节边界）而非特定语言的音素。因此，理论上无需改动内容编码器。可能需要调整的是：（1）训练数据应使用目标语言的录音；（2）F0范围可能因语言的声调特性不同而需要调整（如中文声调语言的F0变化幅度大于英语）；（3）对于声调语言（中文、泰语），F0不仅表达旋律还表达词义，转换时需要更精确的F0控制以避免改变词义。整体来说，系统的跨语言扩展性较好，这得益于自监督模型的语言无关特性。

Q10: 从工程角度，整个Pipeline的实时性如何？瓶颈在哪里?

各阶段耗时（在NVIDIA A800上，处理5分27秒音频）：Demucs分离约20秒，RVC推理约15秒，合唱处理约3秒，混合约2秒，评估约30秒。总计约70秒（不含训练），远快于歌曲时长，可以在实际应用中做到离线近实时。如果要追求真正的实时处理（streaming），瓶颈在Demucs——htdemucs_ft使用全局注意力，无法流式处理。替代方案：使用Demucs的流式变体（latency约1.5秒），或使用更轻量的分离模型（如MDX-Net，质量略低但支持低延迟处理）。RVC本身支持流式推理（约90ms延迟），已可满足直播变声场景。

12. 结论与展望

本文以Hamilton「My Shot」为实验对象，构建了一套完整的歌声克隆系统并进行了深入的技术分析。主要结论如下：

第一，声源分离是Pipeline质量的基石。消融实验表明，去除Demucs分离后所有指标全面恶化（MCD +68%，F0-RMSE +131%，SpkSim -29%），在复杂编曲场景中不可省略。Demucs的双域融合架构通过同时利用时域和频域的优势，实现了8.5 dB的人声分离SDR，但仍是整个Pipeline的性能瓶颈。

第二，合唱段落需要专门的处理策略。未处理的合唱段MCD比独唱段差58%，本文提出的自适应混合策略（根据声部密度自动选择原声回退或增强F0）将合唱段MCD改善33.8%，F0-Corr从0.723恢复到0.942。

第三，量化评估体系为系统优化提供了客观依据。本文构建的10维指标体系覆盖频谱保真度、音高精度、音色相似度和感知质量四个维度。需要注意的是，每个指标都有其适用范围和局限性，特别是PESQ在歌声场景中的参考价值有限，MOS主观测试是不可替代的最终质量确认手段。

展望方面，四个方向值得深入探索：（1）升级到RVC v2（48kHz，768维HuBERT）以改善高频保真度；（2）引入MOS主观测试作为评估补充；（3）探索端到端方案（RIFT-SVC V3，Vevo1.5）在同一测试集上的对比；（4）研究合唱声部独立分离转换（htdemucs_6s + 多说话人模型）的可行性。随着Flow Matching和DiT架构的成熟，未来可能出现无需外部分离即可处理混合音频的零样本SVC方案，从根本上解决误差累积问题。

参考文献

[1] Defossez, A. et al. (2021). Hybrid Spectrogram and Waveform Source Separation. ISMIR 2021.

[2] Hsu, W.N. et al. (2021). HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction. IEEE/ACM TASLP.

[3] Kim, J. et al. (2021). Conditional Variational Autoencoder with Adversarial Learning for End-to-End Text-to-Speech. ICML 2021.

[4] Wang, X. et al. (2023). RMVPE: A Robust Multi-Voice Pitch Estimation Method. arXiv:2306.15412.

[5] Qian, K. et al. (2022). ContentVec: An Improved Self-Supervised Speech Representation. ICML 2022.

[6] Liu, R. et al. (2022). DiffSVC: A Diffusion Probabilistic Model for Singing Voice Conversion. ICASSP 2022.

[7] Chen, G. et al. (2025). YingMusic-SVC: Real-World Robust Zero-Shot Singing Voice Conversion. arXiv:2512.04793.

[8] Violeta, L.P. et al. (2025). The Singing Voice Conversion Challenge 2025. arXiv:2509.15629.

[9] Jiang, Y. et al. (2025). REF-VC: Robust, Expressive and Fast Zero-Shot Voice Conversion. arXiv:2508.04996.

[10] Li, N. et al. (2025). USM-VC: Mitigating Timbre Leakage with USM Residual Block. arXiv:2504.08524.

[11] RVC Project. Retrieval-based Voice Conversion WebUI. github.com/RVC-Project

[12] Facebook/Meta. Demucs: Music Source Separation. github.com/facebookresearch/demucs

[13] Rix, A.W. et al. (2001). Perceptual Evaluation of Speech Quality (PESQ). ITU-T P.862.

[14] Kubichek, R.F. (1993). Mel-Cepstral Distance Measure for Objective Speech Quality Assessment. IEEE Pacific Rim Conf.

[15] RIFT-SVC Project. Rectified Flow Transformer for SVC. github.com/RIFT-SVC

[16] Amphion/Vevo Project. Controllable and Expressive Zero-Shot Voice. github.com/open-mmlab/Amphion

[17] Johnson, J. et al. (2019). Billion-Scale Similarity Search with GPUs (FAISS). IEEE Trans. on Big Data.

[18] Kong, J. et al. (2020). HiFi-GAN: Generative Adversarial Networks for Efficient and High Fidelity Speech Synthesis. NeurIPS 2020.