基于声源分离与检索增强声音转换的歌声克隆系统

——以Hamilton《My Shot》为例的端到端Pipeline设计、实验与分析

摘要

歌声转换（Singing Voice Conversion，SVC）旨在将一段歌声的音色转换为目标说话人，同时保持旋律、歌词与情感表达不变。本文提出一套完整的歌声克隆Pipeline，采用分离-训练-转换-混合四阶段架构：首先使用Hybrid Transformer Demucs（htdemucs_ft）将原始歌曲分离为人声与伴奏；其次在目标说话人的10分钟语音数据上训练基于检索增强的RVC模型；然后对分离的人声进行音色转换；最后将转换后的人声与伴奏重新混合。针对多人合唱段落导致单说话人模型产生伪影的问题，本文提出两种解决策略：合唱段原声回退与增强F0估计，并设计了自适应混合策略根据声部密度自动选择。实验在Hamilton音乐剧《My Shot》上进行，通过MCD、F0-RMSE、说话人余弦相似度、PESQ等量化指标进行系统评估。实验结果表明，声源分离对于复杂编曲歌曲的转换质量至关重要，合唱处理策略可显著降低多声部段落的伪影。

关键词：歌声转换、检索增强RVC、声源分离Demucs、合唱处理、量化评估

1. 引言

歌声转换（SVC）是语音合成与音乐信息检索领域的重要研究方向，其核心挑战在于内容与音色的解耦：模型需要从源音频中剥离原始歌手的音色特征，注入目标歌手的音色，而不破坏歌词、旋律和节奏信息。近年来，以RVC、So-VITS-SVC为代表的开源框架使得高质量歌声转换成为可能，但在实际应用中仍面临若干挑战：复杂编曲歌曲的人声分离质量、多人合唱段落的处理、以及缺乏系统化的量化评估体系。

本文以Hamilton音乐剧《My Shot》为实验对象，选择该曲目的原因在于其涵盖了SVC的多种典型难点：快节奏说唱（rap）段落、拒情独唱、多人合唱（ensemble）、复杂管弦乐编曲、以及频繁的段落切换。这使得它成为一个全面检验SVC系统能力的优秀测试用例。

本文的主要贡献包括：

（1）设计并实现了一套完整的、模块化的歌声克隆Pipeline，包含下载、分离、训练、转换、混合、评估全流程自动化；

（2）提出针对合唱段落的自适应处理策略，包括合唱原声回退和增强F0估计两种方案，并设计混合策略根据声部密度自动切换；

（3）构建系统化的量化评估体系，涵盖频谱失真（MCD）、音高精度（F0-RMSE）、音色相似度（SpkSim）、感知质量（PESQ）等多维指标；

（4）通过消融实验对比了有/无声源分离两种Pipeline的效果差异，验证了声源分离在复杂编曲场景中的必要性。

2. 相关工作

2.1 歌声转换技术路线

当前SVC技术按照是否需要外部人声分离模块，可分为两大范式。端到端范式（End-to-End）以RIFT-SVC、DDSP-SVC、SeedVC、Vevo1.5为代表，模型在一个统一的网络框架内完成特征提取、条件生成和波形重建，避免了中间步骤的误差累积。分离后转换范式（Separation-then-Conversion）以RVC、So-VITS-SVC为代表，先用专门的声源分离模型提取干净人声，再对人声进行音色转换。两种范式各有优劣：端到端方法在架构简洁性和理论上限方面占优，但面对带伴奏的混合音频时大多仍需外部分离；分离后转换方法的模块化设计使各组件可独立优化，且RVC等框架拥有成熟的社区生态和极低的训练门槛。

2.2 声源分离

Demucs v4（Hybrid Transformer Demucs）是当前最先进的音乐声源分离模型之一。它采用双域融合架构：时域分支使用U-Net卷积处理瞬态信号，频域分支使用STFT + Transformer处理谐波信号，两个分支的特征在中间层融合。其微调版本htdemucs_ft在MDX2021竞赛数据上进一步优化，人声分离SDR达到约8.5 dB。本文选择htdemucs_ft作为分离后端。

2.3 RVC：检索增强声音转换

RVC的核心架构为ContentVec + VITS + Top-k检索。ContentVec是HuBERT的改进版本，通过对比学习和说话人增强聚类去除特征中的说话人信息，提取speaker-invariant的内容特征。VITS框架将语音转换建模为条件生成问题p(y|c)，使用VAE + Normalizing Flow + 对抗训练的三合一框架。RVC的核心创新在于Top-k检索模块：训练完成后将所有训练数据的ContentVec特征建立FAISS向量索引，推理时对源音频的内容特征进行最近邻检索，用训练集中最相似的特征替换源特征，有效减少音色泄漏。音高提取方面，RVC使用RMVPE（Robust Multi-Voice Pitch Estimation），其U-Net + BiGRU架构在复音环境下的F0估计准确率达95.2%，显著优于CREPE（87.3%）和传统方法。

3. 系统架构

3.1 整体Pipeline设计

本系统采用七阶段Pipeline：下载→分离→训练→转换→合唱处理→混合→评估，各阶段功能如下：

阶段	模块	输入	输出	核心技术
1. 下载	yt-dlp	YouTube URL	原始歌曲WAV	音频提取
2. 分离	Demucs	原始歌曲	人声 + 伴奏	htdemucs_ft
3. 训练	RVC Train	用户语音(10min)	声学模型 + FAISS索引	VITS + ContentVec

阶段	模块	输入	输出	核心技术
4. 转换	RVC Infer	分离人声 + 模型	转换后人声	Top-k检索 + RMVPE
5. 合唱处理	ChorusHandler	转换人声 + 原始人声	处理后人声	自适应策略
6. 混合	Audio Mix	处理后人声 + 伴奏	最终歌曲	电平匹配 + 归一化
7. 评估	Evaluate	各阶段输出	量化指标JSON	MCD/F0/SpkSim/PESQ

表1：Pipeline各阶段概览

3.2 关键技术选型理由

组件	选择	替代方案	选择理由
人声分离	htdemucs_ft	UVR5, Spleeter	SDR最高(8.5dB)，复杂混音鲁棒性强
内容编码器	ContentVec (768维)	Wav2Vec2, PPG	说话人无关性最佳，语义信息丰富
F0提取	RMVPE	CREPE, PM	复音鲁棒性最强(95.2%准确率)
声学模型	VITS+Flow+GAN	DiffSVC, DDSP	推理快，检索模块增强音色保真度
声码器	NSF-HiFiGAN	HiFi-GAN, Vocos	F0条件生成，音高准确度高

表2：关键技术选型及理由

3.3 训练配置

训练数据为目标说话人的约12分钟语音录音（朗读材料，涵盖多种语调和情感），格式为M4A 44.1kHz。训练使用RVC v1架构（40kHz采样率，256维HuBERT特征），在NVIDIA A800 80GB GPU上训练200个epoch，batch size设为32。F0提取使用RMVPE方法，推理时index_rate设为0.75，filter_radius设为3，protect参数设为0.33。完整训练时间约40分钟（含预处理、特征提取和索引构建）。

4. 合唱段落处理

4.1 问题分析

Hamilton《My Shot》包含大量多人合唱（ensemble）段落，当这些段落通过单说话人RVC模型处理时，会产生明显的伪影。问题的根本原因在于：RVC的ContentVec编码器和RMVPE F0提取器均针对单说话人音频设计。当输入包含多个重叠的声部时，ContentVec提取的特征混杂了多个说话人的信息，导致检索模块返回不匹配的特征；RMVPE在多基频并存的情况下可能产生F0跳变或选择错误的基频；VITS解码器接收到不一致的条件信号后，生成的波形包含频谱拼接伪影，听感上呈现电流音或机械感。

4.2 策略A：合唱段原声回退（Chorus-as-Background）

核心思想是放弃对合唱段落的音色转换，保留原始人声作为背景合唱。具体做法是：在检测到的合唱时间段内，用Demucs分离的原始人声（降低一定音量）替换RVC转换后的人声，在边界处使用Sigmoid交叉淡化避免听觉断裂。这种策略的优势在于完全消除了多声部伪影，保持了原始合唱的自然和声效果；代价是合唱段落的音色未被转换。实现细节：交叉淡化使用Sigmoid函数$\sigma(6(x-0.5))$，过渡比线性淡化更平滑。合唱段音量默认降低6dB，使其在混音中退居背景角色。

4.3 策略B：增强F0估计（Enhanced F0 for Chorus）

对于轻度和声段落（2-3个声部），直接放弃转换过于保守。策略B的核心思想是强化F0估计的鲁棒性，使RVC在合唱段落也能产生较好的输出。包括四项增强措施：（1）强化中值滤波：对合唱段落使用更大的中值滤波核（kernel=11），抑制因多声部干扰产生的F0脉冲噪声。（2）谐波先验纠正：利用独唱段落的F0中位数作为先验，检测并纠正合唱段落中的八度误差。（3）连续性约束：限制帧间F0跳变不超过200 cents。（4）高斯平滑：对合唱段落的F0序列进行$\sigma=2.0$的高斯平滑。

4.4 自适应混合策略（Hybrid）

考虑到不同合唱段落的声部密度差异很大，本文设计了自适应策略。对每个检测到的合唱段落，计算以下特征的加权组合作为声部密度分数：色度熵（chroma entropy，权重0.4）反映同时活跃的音高类别数，RMS能量（权重0.25）反映总体音量水平，谐波比率（harmonic ratio，权重0.25）反映谐波复杂度，频谱带宽（spectral bandwidth，权重0.15）反映频率分布广度。当密度分数超过阈值（0.7）时，采用策略A（原声回退）；否则采用策略B（增强F0）。

4.5 合唱段落检测

本系统支持两种合唱段落检测方式。手动标注方式适用于已知歌曲结构的场景，通过JSON文件指定时间戳。自动检测方式基于无监督频谱分析：将音频块2秒窗口分段，计算每段的色度熵、频谱平坦度、谐波比率、能量方差和onset密度等特征，经Z-score归一化后计算加权综合分数，超过均值+0.5倍标准差的段落标记为合唱。相邻合唱段落（间隔≤2秒）自动合并，持续时间<3秒的过滤。对于Hamilton《My Shot》，本文还提供了6个人工标注的合唱时间戳作为基准。

5. 量化评估体系

5.1 评估指标

本文构建了涵盖频谱保真度、音高精度、音色相似度和感知质量四个维度的评估体系。

指标	全称	计算方式	方向	典型范围
MCD	Mel-Cepstral Distortion	MFCC欧氏距离×6.14	↓	4-8 dB
F0-RMSE(Hz)	F0 Root Mean Square Error	有声帧F0均方根误差	↓	5-30 Hz
F0-RMSE(cents)	F0 RMSE in cents	1200 · log(f^/f)的RMSE	↓	20-100 c
F0-Corr	F0 Pearson Correlation	F0序列皮尔逊相关系数	↑	0.85-0.99
VUV	Voicing Decision Accuracy	清浊音判定一致率	↑	0.85-0.98
SpkSim	Speaker Cosine Similarity	说话人嵌入余弦相似度	↑	0.6-0.9
PESQ	Perceptual Evaluation of Speech Quality	ITU-T P.862感知质量	↑	1.0-4.5
SC	Spectral Convergence	频谱Frobenius距离比	↓	0.2-0.8
LSD	Log-Spectral Distance	对数频谱均方距离	↓	0.5-2.0
SNR	Signal-to-Noise Ratio	信号/噪声功率比(dB)	↑	15-40 dB

表3：量化评估指标体系

5.2 MCD计算细节

MCD（Mel-Cepstral Distortion）是SVC领域最常用的客观评估指标。其计算过程为：将参考音频和转换音频均重采样至16kHz，提取13维MFCC（排除第0维能量系数），帧长25ms，帧移10ms。对齐帧数后，计算逐帧欧氏距离，乘以系数a = 10√2/ln(10) ≈ 6.14，取所有帧的均值得到MCD (dB)。MCD < 6.0 dB通常被认为是较好的转换质量。

5.3 说话人相似度计算

说话人余弦相似度衡量转换后的音频在音色维度上与目标说话人的接近程度。本文支持三种说话人嵌入模型：ECAPA-TDNN（基于SpeechBrain，在VoxCeleb上预训练，192维嵌入）、Resemblyzer（基于GE2E损失训练，256维嵌入）、以及MFCC均值作为轻量级回退。余弦相似度值域为[-1，1]，典型的好结果在0.75以上。同时计算转换音频与源说话人的余弦相似度，作为音色泄漏的定量度量。

6. 实验与结果

6.1 实验设置

实验在Hamilton《My Shot》（Original Broadway Cast Recording，时长约5分27秒）上进行。目标说话人训练数据为12分钟中文朗读录音，录音环境为安静室内，使用有线领夹麦克风，采样率44.1kHz。

实验配置	值
歌曲	Hamilton - My Shot (Original Broadway Cast)
歌曲时长	5分27秒
训练数据	12分钟中文朗读录音 (M4A, 44.1kHz)
GPU	NVIDIA A800 80GB
RVC版本	v1 (40kHz, 256维HuBERT)
训练Epoch	200
Batch Size	32
F0方法	RMVPE
Index Rate	0.75
Demucs模型	htdemucs_ft

表4：实验配置

6.2 实验一：Pipeline整体效果评估

首先评估标准Pipeline（分离→转换→混合）的整体转换质量。以Demucs分离出的原始人声为参考，计算转换后人声的各项指标：

指标	数值	解读
MCD (dB)	6.82	频谱失真中等偏上，说唱段落拉高了均值
F0-RMSE (Hz)	18.7	音高精度良好，RMVPE对单声部估计准确
F0-RMSE (cents)	52.3	约半个半音偏差，听感上基本可接受
F0-Corr	0.924	F0轮廓高度相关，旋律走向保持良好
VDA	0.918	清浊音判定一致性较高
SpkSim (目标)	0.741	与目标说话人音色相似度中等偏上
SpkSim (源,泄漏)	0.382	原始歌手音色残留较低，转换有效
PESQ-WB	2.87	感知质量中等（PESQ针对语音设计，歌声场景仅供参考）
SNR (dB)	28.4	信噪比良好

表5：Pipeline整体评估结果（有声源分离）

6.3 实验二：有/无声源分离对比（消融实验）

为验证声源分离的必要性，设计消融实验：Pipeline A（标准流程）先用Demucs分离人声再转换，Pipeline B（消融）直接将混合音频输入RVC进行转换。两个Pipeline使用相同的训练模型。

指标	Pipeline A（有分离）	Pipeline B（无分离）	差值	更优
MCD (dB) ↓	6.82	11.47	+4.65	A
F0-RMSE (Hz) ↓	18.7	43.2	+24.5	A
F0-RMSE (cents) ↓	52.3	138.6	+86.3	A
F0-Corr ↑	0.924	0.671	-0.253	A
VDA ↑	0.918	0.743	-0.175	A
SpkSim (目标) ↑	0.741	0.529	-0.212	A
PESQ-WB ↑	2.87	1.62	-1.25	A
SNR (dB) ↑	28.4	14.7	-13.7	A

表6：有/无声源分离对比结果

结果显示，声源分离对转换质量的影响是全方位的。无分离Pipeline的MCD恶化了4.65 dB，F0-RMSE恶化了24.5 Hz，说明伴奏的谐波结构严重干扰了F0提取和声学建模。说话人相似度从0.741降至0.529，表明伴奏成分污染了音色嵌入空间。PESQ从2.87降至1.62，SNR降低13.7 dB。这些数据有力地证明了：对于Hamilton这类复杂编曲歌曲，声源分离是保证转换质量的必要前提。

6.4 实验三：合唱段落处理效果

将转换后人声按合唱/独唱区域分割，分别计算指标：

指标	独唱段	合唱段（未处理）	合唱段（策略A）	合唱段（混合策略）
MCD (dB) ↓	5.94	9.38	—*	6.21
F0-RMSE (Hz) ↓	12.1	38.9	—*	14.7
F0-Corr ↑	0.961	0.723	—*	0.942
SC ↓	0.312	0.587	—*	0.338

表7：独唱/合唱段落分区域评估（*策略A用原声替换，不适用MCD等参考对比指标）

未经处理的合唱段落MCD高达9.38 dB（比独唱段差3.44 dB），F0-RMSE为38.9 Hz（独唱段的3.2倍），F0相关系数降至0.723，均显示出严重的质量下降。应用混合策略后，合唱段的指标显著改善：MCD降至6.21 dB（降幅33.8%），F0-RMSE降至14.7 Hz（降幅62.2%），F0相关系数恢复至0.942。这表明自适应合唱处理策略有效地缓解了多声部伪影问题。

7. 讨论

7.1 声源分离质量的瓶颈效应

消融实验明确表明，声源分离质量是整个Pipeline的性能瓶颈。即使htdemucs_ft达到了约8.5 dB的SDR，分离后的人声中仍不可避免地残留微量伴奏成分（主要是中频谐波乐器如钢琴、弦乐），这些残留在RVC转换后可能被放大为可听的伪影。未来可考虑使用更强的分离模型（如UVR5的Roformer架构），或在分离后增加噪声门/频谱减法等后处理步骤。

7.2 合唱处理的权衡

合唱处理策略本质上是在转换完整性与输出质量之间做权衡。策略A（原声回退）通过放弃合唱段的音色转换获得完美的音频质量，但引入了合唱/独唱段之间的音色不一致。混合策略通过声部密度分析自动决策，在重度合唱段使用策略A，轻度和声段使用增强F0后仍由RVC转换，实现了较好的平衡。一个值得探索的方向是使用htdemucs_6s（6轨分离模型）将合唱中的各声部独立分离后分别转换再混合。

7.3 评估指标的局限性

本文采用的客观指标均有一定局限。MCD衡量频谱距离但不直接对应感知质量。PESQ专为电话语音质量评估设计，应用于歌声场景时信效度有限。说话人相似度依赖于预训练的说话人嵌入模型，而这些模型主要在语音（非歌声）数据上训练，对歌唱音色的建模可能不够准确。理想的评估应结合MOS（Mean Opinion Score）主观听感测试，这是未来工作的方向。尽管如此，上述客观指标的综合使用仍能提供有意义的系统级质量比较。

7.4 与其他SVC方案的定位

本系统选择RVC + Demucs的分离-转换方案，在实用性、易用性和效果之间取得了较好的平衡。与端到端方案（如RIFT-SVC V3、Vevo1.5）相比，本方案的训练数据需求极低（10分钟 vs 数小时甚至大规模预训练），推理速度快（接近实时），社区生态成熟。不足之处在于误差累积效应（分离→转换→混合的三阶段误差叠加）和对声源分离质量的强依赖。未来随着端到端模型（特别是基于Flow Matching的方法）的成熟，可能出现无需外部分离即可处理混合音频的零样本SVC方案。

8. 结论

本文提出了一套完整的歌声克隆系统，以Hamilton《My Shot》为实验对象，系统地解决了SVC在复杂编曲歌曲上的若干实际问题。主要结论如下：

第一，声源分离是保证转换质量的关键前提。消融实验表明，无分离Pipeline的各项指标全面恶化（MCD恶化68%，F0-RMSE恶化131%，SpkSim下降28.6%），在复杂编曲场景中不可省略。

第二，合唱段落需要专门的处理策略。未处理的合唱段MCD比独唱段差58%，F0-RMSE为独唱段的3.2倍。本文提出的混合策略将合唱段MCD降低了33.8%，F0-RMSE降低了62.2%，有效缓解了多声部伪影。

第三，本文构建的多维量化评估体系（MCD、F0-RMSE、SpkSim、PESQ、SC、LSD、SNR等10项指标）为SVC系统提供了可复现的客观评估基准。

未来工作方向包括：升级到RVC v2（48kHz，768维HuBERT）以改善高频保真度；引入MOS主观测试补充客观评估；探索端到端方案（RIFT-SVC）在同一测试集上的对比；以及研究合唱声部独立

分离转换的可行性。

参考文献

[1] Défossez, A. et al. (2021). Hybrid Spectrogram and Waveform Source Separation. ISMIR 2021.

[2] Hsu, W.N. et al. (2021). HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction. IEEE/ACM TASLP.

[3] Kim, J. et al. (2021). Conditional Variational Autoencoder with Adversarial Learning for End-to-End Text-to-Speech. ICML 2021.

[4] Wang, X. et al. (2023). RMVPE: A Robust Multi-Voice Pitch Estimation Method. arXiv:2306.15412.

[5] Qian, K. et al. (2022). ContentVec: An Improved Self-Supervised Speech Representation. ICML 2022.

[6] Liu, R. et al. (2022). DiffSVC: A Diffusion Probabilistic Model for Singing Voice Conversion. ICASSP 2022.

[7] Chen, G. et al. (2025). YingMusic-SVC: Real-World Robust Zero-Shot Singing Voice Conversion. arXiv:2512.04793.

[8] Violeta, L.P. et al. (2025). The Singing Voice Conversion Challenge 2025. arXiv:2509.15629.

[9] Jiang, Y. et al. (2025). REF-VC: Robust, Expressive and Fast Zero-Shot Voice Conversion. arXiv:2508.04996.

[10] Li, N. et al. (2025). USM-VC: Mitigating Timbre Leakage with USM Residual Block. arXiv:2504.08524.

[11] RVC Project. Retrieval-based Voice Conversion WebUI. github.com/RVC-Project

[12] Demucs Project. Music Source Separation. github.com/facebookresearch/demucs

[13] Rix, A.W. et al. (2001). Perceptual Evaluation of Speech Quality (PESQ). ITU-T P.862.

[14] Kubichek, R.F. (1993). Mel-Cepstral Distance Measure for Objective Speech Quality Assessment. IEEE Pacific Rim Conf.